

**Membangun sebuah Combinatory Categorical
Grammar (CCG) Supertagger berbasis
Maximum Entropy untuk Bahasa Indonesia**

Proposal Tugas Akhir

Kelas TA NLP

Wisnu Adi Nurcahyo

NIM: 1301160479



Program Studi Sarjana Informatika

Fakultas Informatika

Universitas Telkom

Bandung

2019

Lembar Persetujuan

**Membangun sebuah Combinatory Categorical Grammar (CCG)
Supertagger berbasis Maximum Entropy untuk Bahasa Indonesia**

***Building a Maximum Entropy based Combinatory Categorical
Grammar (CCG) Supertagger for Bahasa Indonesia***

**Wisnu Adi Nurcahyo
NIM: 1301160479**

Proposal ini diajukan sebagai usulan pembuatan tugas akhir pada
Program Studi Sarjana Informatika
Fakultas Informatika Universitas Telkom

Bandung, 24 Oktober 2019
Menyetujui

Calon Pembimbing 1

Dr. Ade Romadhony, S.T., M.T.
NIP: 06840042

Abstrak

Dalam pemrosesan bahasa alami, combinatory categorial grammar (CCG) merupakan salah satu formalisme tata bahasa yang dapat digunakan untuk membangun sebuah *parser* yang umumnya dikenal sebagai CCG *parser*. CCG *parser* dapat digunakan untuk berbagai macam keperluan dalam pemrosesan bahasa alami. Sebagai contoh, CCG *parser* dapat digunakan untuk memperoleh informasi (*information extraction*) dari suatu kalimat yang kemudian membentuk sebuah *query*. Agar dapat bekerja, CCG *parser* membutuhkan CCG *lexicon*. CCG *lexicon* diperoleh dari proses yang bernama *supertagging*. *Supertagging* adalah proses pelabelan suatu token kata terhadap *supertag*-nya. Perangkat lunak yang melakukan *supertagging* disebut sebagai *supertagger*. Demikian itu, *supertagging* merupakan langkah pertama yang perlu dilakukan sebelum membangun sebuah CCG *parser*. *Supertagger* yang dibangun dalam tugas akhir ini dimaksudkan sebagai produsen CCG *lexicon* bahasa Indonesia untuk riset-riset yang berkenaan dengan CCG di masa yang akan datang.

Kata Kunci: natural language processing, combinatory categorial grammar, supertagger, maximum entropy model, bahasa indonesia, haskell

Daftar Isi

Abstrak	i
Daftar Isi	ii
I Pendahuluan	1
1.1 Latar Belakang	1
1.2 Perumusan Masalah	1
1.3 Tujuan	2
1.4 Batasan Masalah	2
1.5 Rencana Kegiatan	2
1.6 Jadwal Kegiatan	2
II Kajian Pustaka	4
2.1 Categorical Grammar	4
2.2 Combinatory Categorical Grammar	4
2.3 Category Theory	4
2.4 Lambda Calculus	5
2.5 Supertagging	5
2.6 Maximum Entropy Model	5
Daftar Pustaka	6
Lampiran	7

Bab I

Pendahuluan

1.1 Latar Belakang

Riset pemrosesan bahasa natural untuk bahasa Indonesia saat ini terbilang sedikit. Bahkan, masih banyak area riset yang belum tersentuh seperti contohnya *combinatory categorial grammar* (CCG). CCG merupakan formalisme tata bahasa yang salah satu manfaatnya adalah untuk memperoleh informasi (*information extraction*) dari suatu kalimat. Informasi tersebut diperoleh setelah melakukan *parsing* berdasarkan formalisme CCG dengan menggunakan perangkat lunak bernama CCG *parser*. Untuk dapat melakukan *parsing*, CCG *parser* membutuhkan CCG *lexicon* yang mengandung bentuk formal dari suatu token kata. Bentuk formal yang dimaksud adalah *category* dalam *category theory*. CCG *lexicon* diperoleh dari proses pelabelan suatu token kata terhadap bentuk formalnya yang mana dikenal sebagai *supertagging*. Proses *supertagging* akan menghasilkan *supertag* yang kemudian disebut sebagai CCG *supertag* karena formalisme yang digunakan adalah formalisme CCG. Dalam hal ini, CCG *supertag* adalah CCG *lexicon* itu sendiri.

Tugas akhir dengan judul “Membangun sebuah Combinatory Categorical Grammar (CCG) Supertagger berbasis Maximum Entropy untuk Bahasa Indonesia” berusaha untuk membangun versi awal dari CCG *supertagger* untuk bahasa Indonesia yang mana harapannya dapat menjadi inisiator riset pemrosesan bahasa natural dengan tema CCG sehingga ke depannya akan ada lebih banyak riset mengenai CCG yang tersedia. *Supertagger* yang dimaksud dalam tugas akhir ini akan dibangun dengan menggunakan model Maximum Entropy (MaxEnt) dan implementasinya akan ditulis dalam bahasa pemrograman Haskell. Model MaxEnt digunakan karena keterbatasan *dataset* untuk melakukan *learning*. Adapun bahasa pemrograman Haskell digunakan karena abstraksi bahasanya yang sangat mendekati *category theory* serta kemampuannya yang sangat baik dalam pemrosesan data.

1.2 Perumusan Masalah

Rumusan masalah yang akan diangkat yaitu:

1. Mengapa CCG *supertagger* diperlukan?

2. Apa saja yang harus dipersiapkan untuk membangun CCG *supertagger*?
3. Bagaimana proses pembangunan CCG *supertagger*?

1.3 Tujuan

Tujuan yang diharapkan dapat tercapai oleh tugas akhir ini yaitu:

1. Mengenalkan alternatif metode yang dapat digunakan dalam pemrosesan bahasa alami untuk bahasa Indonesia.
2. Merilis CCG *supertagger* pertama untuk bahasa Indonesia.
3. Membuka peluang riset untuk CCG *parser* bahasa Indonesia.

1.4 Batasan Masalah

Hipotesis dari tugas akhir ini yaitu:

1. Memberikan label CCG untuk proses *learning* merupakan permasalahan utama dari tugas akhir ini.
2. *Supertagger* yang akan dibangun kemungkinan besar memiliki akurasi yang cenderung rendah.
3. CCG *lexicon* sudah dapat digunakan oleh CCG *parser* bahasa Indonesia (apabila ada).

1.5 Rencana Kegiatan

Rencana kegiatan yang akan dilakukan adalah sebagai berikut:

- Studi literatur
- Studi *tools* yang tersedia
- Studi bahasa pemrograman yang akan digunakan
- Perancangan sistem *supertagger*
- Membangun *supertagger*
- Memeriksa hasil

1.6 Jadwal Kegiatan

Laporan proposal ini akan dijadwalkan sesuai dengan tabel 1.1.

Tabel 1.1: Jadwal kegiatan proposal tugas akhir.

No	Kegiatan	Bulan ke-																										
		1				2				3				4				5				6						
1	Studi Literatur																											
2	Studi <i>Tools</i> yang Tersedia																											
3	Studi Bahasa Pemrograman																											
4	Pengumpulan Data																											
5	Analisis dan Perancangan Sistem																											
6	Implementasi Sistem																											
7	Analisa Hasil Implementasi																											
8	Penulisan Laporan																											

Bab II

Kajian Pustaka

2.1 Categorical Grammar

Categorical Grammar (CG) merupakan sebuah istilah yang mencakup beberapa formalisme terkait yang diajukan untuk sintaks dan semantik dari bahasa alami serta untuk bahasa logis dan matematis [1]. Karakteristik yang paling terlihat dari CG adalah bentuk esktrim dari leksikalismenya di mana beban utama (atau bahkan seluruh beban) sintaksisnya ditanggung oleh leksikon. Konstituen tata bahasa dalam *categorical grammar* dan khususnya semua leksikal diasosiasikan dengan suatu *type* atau “*category*” (dalam *category theory*) yang mendefinisikan potensi mereka untuk dikombinasikan dengan konstituen lain untuk menghasilkan konstituen majemuk. *Category* tersebut adalah salah satu dari sejumlah kecil *category* dasar (seperti NP) atau *functor* (dalam *category theory*).

Ada beberapa notasi berbeda untuk *category* dalam merepresentasikan *directional*-nya. Notasi yang paling umum digunakan adalah “*slash notation*” yang dipelopori oleh Bar-Hilel, Lambek, dan kemudian dimodifikasi dalam kelompok teori yang dibedakan sebagai tata bahasa “*combinatory*” *categorical grammar* (CCG). Sebagai contoh, *category* $(S \backslash NP) / NP$ merupakan suatu *functor* yang memiliki dua buah notasi *slash* yaitu \backslash dan $/$. Masing-masing notasi *slash* tersebut merepresentasikan *directionality* yang berbeda. Notasi *forward slash*, $/$, mengindikasikan bahwa argumen dari suatu *functor* X/Y ada di bagian kanan atau dengan kata lain Y . Adapun *backward slash*, \backslash , mengindikasikan bahwa argumen dari suatu *functor* $X \backslash Y$ ada di bagian kiri atau dengan kata lain X .

2.2 Combinatory Categorical Grammar

TBA.

2.3 Category Theory

TBA.

2.4 Lambda Calculus

TBA.

2.5 Supertagging

TBA.

2.6 Maximum Entropy Model

TBA.

Daftar Pustaka

- [1] Mark Steedman. Categorical grammar. Technical report, 1992.

Lampiran